

## CCAC2023 多模态对话中的情感识别任务

河南省网络舆情监测与智能分析重点实验室

#### 任务描述与分析

01

任

务

分

析

- 任务目标:对多模态对话中的情感进行识别
- 任务数据: M3ED数据集,源于56部中文电视剧的 990 个情感二人对话视频 片段,标签为平静、开心、惊讶、难过、厌恶、生气和害怕等7种情感。
- 评价指标:以多分类macro F1值作为评测指标通过分析任务描述,我们发现
- 该问题可以当作文本多分类任务来处理
- 适用该问题的模型比较多,仅需要调整输入输出以及微调模型参数
- 通过对任务数据进行分析,发现原始数据存在分布不均等问题,而机器学习模型普遍对数据的要求较高,因此如何处理好数据是本任务的关键

### **Pipeline**

02

解

决

方

案

数据预处理



模型选择



数据增强



模型训练

数据提取

上下文拼接

文本截断、补齐

向量化

Bert

Bert-wwm

Reberta

**ERNIE** 

随机实体识别

近义近音替换

随机置换临近字

Simbert

伪标签

训练参数调整

seed

tricks

•••

01数据预处

| 话语编号            | 开始时间        | 结束时间        | 文本           | 说话者 | 情感 |
|-----------------|-------------|-------------|--------------|-----|----|
| fumuaiqing_1_1  | 00:00:00:03 | 00:00:01:17 | 你是不是有什么事瞒着我? | Α   | 平静 |
| fumuaiqing_1_2  | 00:00:06:00 | 00:00:07:18 | 我是有件事瞒着你     | В   | 平静 |
| fumuaiqing_1_3  | 00:00:10:13 | 00:00:12:04 | 什么事瞒着我啊?     | Α   | 惊讶 |
| fumuaiqing_1_4  | 00:00:19:11 | 00:00:20:04 | 小安           | В   | 难过 |
| fumuaiqing_1_5  | 00:00:22:23 | 00:00:23:19 | 对不起了         | В   | 难过 |
| fumuaiqing_1_6  | 00:00:26:05 | 00:00:28:08 | 没有事先告诉你      | В   | 难过 |
| fumuaiqing_1_7  | 00:00:28:23 | 00:00:31:18 | 其实我我         | В   | 害怕 |
| fumuaiqing_1_8  | 00:00:34:17 | 00:00:35:22 | 我是离过婚的       | В   | 害怕 |
| fumuaiqing_1_9  | 00:00:42:07 | 00:00:45:10 | 什么?你结过婚?     | Α   | 惊讶 |
| fumuaiqing_1_10 | 00:00:47:23 | 00:00:49:18 | 我结过婚         | В   | 难过 |
| fumuaiqing_1_11 | 00:00:52:05 | 00:00:54:18 | 不过我已经离了我离了   | В   | 害怕 |
| fumuaiqing_1_12 | 00:00:59:08 | 00:01:01:00 | 安杰 你听我说你坐下   | В   | 害怕 |
| fumuaiqing_1_13 | 00:01:01:06 | 00:01:02:10 | 你这个骗子        | Α   | 生气 |

| count | 17427.000000 |
|-------|--------------|
| mean  | 7.406955     |
| std   | 2.981791     |
| min   | 1.000000     |
| 25%   | 5.000000     |
| 50%   | 7.000000     |
| 75%   | 9.000000     |
| max   | 20.000000    |
|       |              |
|       |              |
| count | 17427.000000 |
| mean  | 89.113961    |
| std   | 32.348111    |
| min   | 1.000000     |
| 25%   | 79.000000    |
| 50%   | 100.000000   |
|       |              |
| 75%   | 110.000000   |

理

| 上下文数量 | 0      | 1      | 2      | 3      | 4      | 5      | 6      | 7      | 8      | 9      |
|-------|--------|--------|--------|--------|--------|--------|--------|--------|--------|--------|
| F1    | 0.3324 | 0.3727 | 0.3760 | 0.3876 | 0.3934 | 0.3949 | 0.4040 | 0.4065 | 0.3975 | 0.4005 |

# 02

模

型

选

择

|    | bert-base | bert-wwm | bert-wwm-ext | ernie3.0 | roberta-wwm-ext |
|----|-----------|----------|--------------|----------|-----------------|
| F1 | 0.348     | 0.346    | 0.354        | 0.4065   | 0.359           |

- 确定上下文数量7为最优参数
- 主流模型性能分析
- 模型微调(epoch=5,seed=42)
- 确定ernie3为基线模型



03

数

据

#### 分

析

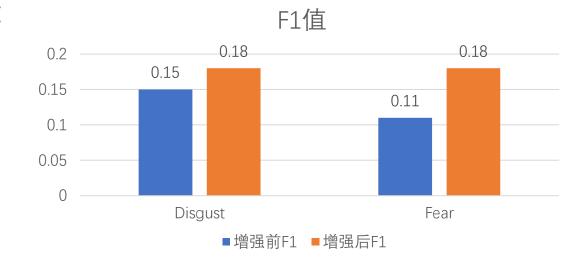


#### 原始数据中存在的问题

- 数据分布不均匀,部分标签对应的数据量过少
- 部分标签的F1值过低,可能由于数据量过少导致 采用数据增强技术解决上述问题

#### 本任务采用的数据增强技术:

- 随机实体识别
- 近义近音替换
- 上下文替换
- 随机置换临近的字等



据

数

04

增



数据增强前后对比

强

|            | 训练集           | 验证集  | 测试集   | F1     |
|------------|---------------|------|-------|--------|
| Model      | 17427         | 2821 | 10276 | 0.4702 |
| Model+数据增强 | 17427+(12250) | 2821 | 10276 | 0.4738 |

04

伪

伪标签方法主要是将模型对无标签的测试数据的预测结果加入到训练集中, 从而增大数据量提升模型效果,适用于<mark>模型精度较高</mark>的情况。我们将基线 模型进行微调,取类别概率大于0.95的数据重新加入到训练集中训练。

标



伪标签后对比

签

|           | 训练集         | 验证集  | 测试集   | F1     |
|-----------|-------------|------|-------|--------|
| Model     | 17427       | 2821 | 10276 | 0.4738 |
| Model+伪标签 | 17427+(476) | 2821 | 10276 | 0.4826 |

**05** 结

果

展

示

|        | 训练集数量  | F1     | 变化      |
|--------|--------|--------|---------|
| 基线模型   | 17427  | 0.3324 |         |
| +上下文信息 | +0     | 0.4702 | +0.1378 |
| +数据增强  | +12250 | 0.4738 | +0.0063 |
| +伪标签   | +476   | 0.4826 | +0.0088 |

#### 总

#### 未完成工作

- 使用多轮伪标签
- 尝试多模型融合
- 尝试加入多模态信息

#### 结